

一种基于差分进化和灰狼算法的混合优化算法

金星 邵珠超 王盛慧*
(长春工业大学电气与电子工程学院, 长春 130012)

摘要 针对差分进化易陷入局部最优和灰狼算法易早熟停滞的缺点,提出了一种基于差分进化(DE)算法和灰狼(GWO)算法的混合优化算法(DEGWO)。该算法利用差分进化的变异、选择算子维持种群的多样性,然后引入灰狼算法与差分进化的交叉、选择算子进行全局搜索。在整个寻优过程中,反复迭代渐进收敛。选取此3个测试函数进行仿真实验,结果表明,混合优化算法相比于DE算法和GWO算法,其求解精度、收敛速度、搜索能力都有了显著提高。

关键词 差分进化 灰狼算法 混合优化算法 测试函数

中图分类号 TP301.6; **文献标志码** A

差分进化(DE)算法由 Storn 和 Price 在 1995 年为求切比雪夫多项式拟合问题而提出一种采用浮点矢量编码在连续空间中随机搜索的优化算法^[1];其核心思想是在当前种群中,对于每一个目标个体通过变异操作生成变异个体,然后变异个体与目标个体进行比较,生成试验个体;如果试验个体与目标个体具有更优的目标函数值,则试验个体取代目标个体成为下一代^[2]。但是对于不同的问题,需要实时调节参数;并且当迭代到某一区域,差异性减少而出现局部最优。

灰狼(GWO)算法最早是由 Mirjalili 等人于 2014 年提出的一种通过模拟灰狼的社会等级和狩猎行为的新群体智能优化算法^[3],通过狼群跟踪、包围、追捕、攻击等形式实现优化的目的。由于该算法不考虑梯度信息、结构简单、参数设置少、全局搜索能力强,故被广泛用于神经网络的寻优领域^[4]。尽管 GWO 算法得到大量的应用,但也和其他的智能算法一样,存在求解精度低、易早熟等缺点。

为改进算法的寻优性能,同时考虑到各自存在的优缺点,本文将 DE 和 GWO 融合起来而提出一种

更为高效的混合优化算法(DEGWO)。首先,该混合算法利用 DE 算法的差分变异生成初始种群保证一定的差异性,然后利用 GWO 全局最优解的搜索能力以确保算法的收敛。测试结果表明,该算法与 DE 算法和 GWO 算法相比,能够加快最优解搜索速度,同时避免早熟现象,达到了预期的效果。

1 差分进化和灰狼算法

1.1 差分进化算法

DE 与传统的进化算法相比,利用随机选择的不同个体生成的比例差分矢量对当前代个体进行扰动,因此无需单独使用概率分布来生成个体^[5]。存在类似于进化算法的计算步骤,包括变异、交叉和选择三种操作。

定义在 D 维搜索空间内,种群规模 N , $X_i(g)$ 是第 g 代的第 i 个个体 $X_i^L(g) \leq X_i(g) \leq X_i^U(g)$, 则 $X_i(g) = [x_{i1}(g), x_{i2}(g), \dots, x_{in}(g)]$; $i = 1, 2, \dots, N, g = 1, 2, \dots, t_{\max}$

式(1)中, $X_i^L(g)$ 为种群个体的下界, $X_i^U(g)$ 为种群个体的上界, t_{\max} 为最大迭代次数。其计算步骤如下:

1.1.1 在整个搜索空间随机生成 N 个初始种群个体

$$x_{ij}(0) = x_{ij}^L + rand(0,1)(x_{ij}^U - x_{ij}^L) \tag{2}$$

式(2)中, $rand(0,1)$ 是 $[0,1]$ 上服从均匀分布的随机数。

1.1.2 变异操作

变异个体由下式生成

$$h_{ij}(g) = x_{p1} + F(x_{p2} - x_{p3}) \tag{3}$$

式(3)中, x_{p1}, x_{p2}, x_{p3} 为当前种群中随机选择的三个不相同参数矢量,并且 $p_1 \neq p_2 \neq p_3 \neq i, F$ 为 $[0,$

2016 年 12 月 1 日收到 吉林省科技发展计划项目(20150203003SF)
资助
第一作者简介:金星(1976—),副教授,硕士。研究方向:测控技术与智能系统。E-mail:jinxing@ccut.edu.cn。
*通信作者简介:王盛慧(1976—),副教授,硕士,研究方向:数字传动与电力节能技术。E-mail:254028565@qq.com。
引用格式:金星,邵珠超,王盛慧.一种基于差分进化和灰狼算法的混合优化算法[J].科学技术与工程,2017,17(16):266—269
Jin Xing, Shao Zhuchao, Wang Shenghui. A hybrid optimization algorithm based on differential evolution and grey wolf optimizer[J]. Science Technology and Engineering, 2017, 17(16): 266—269

1] 之间的缩放比例因子。

1.1.3 交叉操作

交叉操作可以增加种群的多样性,操作如下:

$$v_{ij}(g+1) = \begin{cases} h_{ij}(g), rand(0,1) \leq CR \text{ 或者 } j = rand(1,n) \\ x_{ij}(g), rand(0,1) > CR \text{ 或者 } j \neq rand(1,n) \end{cases} \quad (4)$$

式(4)中,CR为取值[0,1]之间的交叉概率,rand(0,1)是[0,1]上均匀分布的随机数,用于确定至少有一维分量来自目标个体 X_i 。

1.1.4 选择操作

由评价函数对向量 $v_i(g+1)$ 和向量 $x_i(g)$ 进行比较。

$$x_i(g+1) = \begin{cases} v_i(g+1), & f[v_i(g+1)] < f[x_i(g)] \\ x_i(g), & f[v_i(g+1)] \geq f[x_i(g)] \end{cases} \quad (5)$$

因此,通过这种机制可以保证子代种群中至少不比当前个体差,从而使种群的平均性能提高,并达到最优解。

1.2 灰狼算法

假设在D维搜索空间内,种群规模 $X = (X_1, X_2, \dots, X_N)$ 由N个个体组成,定义第i只灰狼的位置为 $X_i = (X_i^1, X_i^2, \dots, X_i^D)$,其中 X_i^d 表示第i只灰狼在第d维上的位置。定义种群中的最优解为狼 α ,目标函数值第二和第三的最优解分别为狼 β 和狼 δ ,其余的候选解为 ω ^[6]。在GWO算法中,狩猎行为由狼 α 、狼 β 和狼 δ 引导,狼 ω 跟随这三只狼进行狩猎。如下公式描述灰狼包围猎物的行为:

$$D = |CX_p(t) - X(t)| \quad (6)$$

$$C = 2r_1 \quad (7)$$

式中,t代表当前迭代次数,C为摇摆因子, $X_p(t)$ 代表第t次迭代后猎物的位置, $X(t)$ 代表第t次迭代灰狼的位置, r_1 为[0,1]间的随机数。

灰狼位置更新公式如下:

$$X(t+1) = X_p(t) - AD \quad (8)$$

$$A = 2ar_2 - a \quad (9)$$

式中,A为收敛因子, r_2 是[0,1]上均匀分布的随机数,变量a随迭代次数的增加从2线性递减到0。

灰狼有能力判断出猎物的位置并展开包围。狩猎行为由 α 引导, β 和 δ 也可能偶尔参与狩猎。然而,在抽象搜索空间中,并不能确定最佳(猎物)的位置。为了数学模拟灰狼的狩猎行为,猜测利用狼 α 、 β 和 δ 去确定猎物的潜在位置。因此,在保存历史获得的前三个的最优值,迫使其他搜索个体(包括 ω)根据最优值的位置不断更新它们的位置。数学

描述如下:

$$D_\alpha = |C_1X_\alpha(t) - X(t)| \quad (10)$$

$$D_\beta = |C_2X_\beta(t) - X(t)| \quad (11)$$

$$D_\delta = |C_3X_\delta(t) - X(t)| \quad (12)$$

$$X_1(t+1) = X_\alpha(t) - A_1D_\alpha \quad (13)$$

$$X_2(t+1) = X_\beta(t) - A_2D_\beta \quad (14)$$

$$X_3(t+1) = X_\delta(t) - A_3D_\delta \quad (15)$$

$$X_p(t+1) = \frac{X_1 + X_2 + X_3}{3} \quad (16)$$

由式(10)~式(15)可计算出其他灰狼个体与 α 、 β 和 δ 的距离及更新后的灰狼位置,然后由式(16)确定猎物所在的方位。

2 差分进化和灰狼混合优化算法

2.1 算法的主要思想

针对DE算法和GWO算法在单独求解优化问题时容易出现早熟、稳定性差、易陷入局部最优等的缺陷,综合两种算法的优缺点,提出一种更为高效的混合优化算法—DEGWO算法来提高全局的搜索能力。首先,为避免种群迭代到一定区域时出现差异性减小的现象,采用DE算法的交叉、选择操作维持种群的多样性,再将其作为GWO算法的初始种群,计算个体的目标函数值,选出最优的三个个体 X_α 、 X_β 和 X_δ ,据此更新其他灰狼个体的位置,然后利用DE的交叉和选择操作对灰狼个体的位置进行更新,反复迭代更新,直到从中选出最优的目标函数值输出。该混合算法即提高了全局搜索能力,又能够有效避免早熟停滞、陷入局部最优的缺陷。

2.2 算法的具体实施步骤

Step1:设置混合优化算法的相关参数,种群规模N,最大迭代次数 t_{max} ,交叉概率CR,搜索维数D,搜索范围ub、lb,缩放因子F范围。

Step2:初始化参数a,A和C,对种群个体按式(3)实施DE变异操作,产生中间个体;然后按式(5)进行竞争选择操作产生初始化种群个体,设置迭代次数 $t=1$ 。

Step3:计算种群中每个灰狼个体的目标函数值,并依据目标函数值的大小进行排序,选出最优的前三个个体分别记为 X_α 、 X_β 和 X_δ 。

Step4:按式(10)~式(12)计算种群中其他灰狼个体与最优的 X_α 、 X_β 和 X_δ 的距离,并依据式(13)~式(16)更新当前每个灰狼个体的位置。

Step5:更新算法中a,A和C的值,按式(4)对种群个体的位置进行交叉操作,保留较优良的成分,然后执行式(5)进行选择产生新的个体,计算所有灰狼个体的目标函数值。

Step6:更新最优值前三的灰狼个体 X_{α} 、 X_{β} 和 X_{δ} 的位置。

Step7:判断计数值,如果达到最大迭代次数 t_{\max} ,则算法退出,同时输出全局最优 X_{α} 的目标函数值;否则,令 $t = t + 1$,转向 Step3 继续执行。

3 实验结果与分析

为了验证 DEGWO 混合算法的寻优性能,本文选用 3 个标准的测试函数进行优化效果测试,并分别与 DE 和 GWO 的优化效果作比较。

3.1 Rastrigin 函数

$$\min f_1(x_i) = \sum_{i=1}^D [x_i^2 - 10\cos 2\pi x_i + 10]。$$

3.2 Griewank 函数

$$f_2(x_i) = \sum_{i=1}^D \frac{x_i^2}{4\,000} - \prod_{i=1}^D \cos\left(\frac{x_i}{\sqrt{i}}\right) + 1。$$

3.3 Ackley 函数

$$f_3(x) = -20\exp\left[-0.2\sqrt{\frac{1}{D}\sum_{i=1}^D x_i^2} - \exp\left(\frac{1}{D}\sum_{i=1}^D \cos 2\pi x_i\right)\right] + 20 + e。$$

设定标准测试函数的参数(空间维数、搜索范围、最优解、最优值)如表 1。

表 1 测试函数的参数设置				
Table 1 Parameter settings of test function				
测试函数	维数	搜索范围	最优值	最优点
Rastrigin	30	[-5. 12 5. 12]	0	(0, ⋯, 0)
Griewank	30	[-600 600]	0	(0, ⋯, 0)
Ackley	30	[-32 32]	0	(0, ⋯, 0)

设定 DEGWO 的相关参数如下:种群规模 $N = 30$,最大迭代次数 $t_{\max} = 500$,缩放比例因子 F 上界为 0. 8、下界为 0. 2,交叉概率 $CR = 0. 2$,收敛因子 a

随迭代次数的增加由 2 动态递减到 0。DE 算法和 GWO 算法的参数设置和 DEGWO 保持一致。

为避免寻优效果的的偶然性,同时也为了证明 DEGWO 算法的稳定性,采取对每种测试函数分别运行 30 次。针对这三个测试函数,三种优化算法给出的关于平均值、最优值、标准差的测试结果如表 2。可知,在满足相同的维数和搜索范围的情况下,DEGWO 算法的平均值、最优值和标准差都优于 DE 算法和 GWO 算法,表现出极强的搜索能力和良好的稳定性。

限于篇幅,针对以上 3 种测试函数的收敛曲线,分别随机从 30 次运行结果中选取 1 次进行分析,如图 1 ~ 图 3。由图可知,DEGWO 的进化曲线变化率均大于 DE 和 GWO,这表明混合优化算法的收敛速度和求解精度均优于其他两种算法。对于 Rastrigin 函数,DEGWO 算法收敛速度快,而 DE 算法和 GWO 算法的目标函数值趋于水平,并没有收敛至全局的最优解;对于 Griewank 函数,DE 算法前期收敛较快,后期则变得缓慢,GWO 则出现早熟的现象;对于 Ackley 函数,DE 算法收敛缓慢,而 GWO 也能实现快速收敛,但是收敛精度逊于 DEGWO。




图 1 Rastrigin 函数的进化曲线
Fig. 1 Evolution curve of Rastrigin function

表 2 DE、GWO 和 DEGWO 关于测试函数效果比较				
Table 2 The test function comparison of DE, GWO and DEGWO				
函数	最优值、迭代数	DE	GWO	DEGWO
Rastrigin	0, 500	标准差 $5.159\,4 \times 10^{-2}$	标准差 $4.567\,1 \times 10^{-5}$	标准差 $1.136\,8 \times 10^{-13}$
		平均值 $9.308\,3 \times 10^{-1}$	平均值 $8.053\,3 \times 10^{-5}$	平均值 $6.439\,1 \times 10^{-12}$
		最优值 $8.641\,8 \times 10^{-2}$	最优值 $5.946\,4 \times 10^{-5}$	最优值 $3.816\,4 \times 10^{-13}$
Griewank	0, 500	标准差 $3.496\,7 \times 10^{-1}$	标准差 $7.682\,8 \times 10^{-8}$	标准差 $6.063\,3 \times 10^{-15}$
		平均值 1. 335 6	平均值 $7.389\,3 \times 10^{-7}$	平均值 $9.394\,3 \times 10^{-15}$
		最优值 $6.645\,7 \times 10^{-1}$	最优值 $8.684\,4 \times 10^{-8}$	最优值 $7.658\,4 \times 10^{-15}$
Ackley	0, 500	标准差 $4.167\,9 \times 10^{-3}$	标准差 $7.576\,2 \times 10^{-10}$	标准差 $2.681\,7 \times 10^{-12}$
		平均值 $7.369\,3 \times 10^{-3}$	平均值 $1.335\,9 \times 10^{-9}$	平均值 $5.953\,3 \times 10^{-12}$
		最优值 $5.936\,4 \times 10^{-3}$	最优值 $9.642\,8 \times 10^{-10}$	最优值 $3.286\,4 \times 10^{-12}$




图2 Griewank 函数的进化曲线

Fig.2 Evolution curve of Griewank function




图3 Ackley 函数的进化曲线

Fig.3 Evolution curve of Ackley function

4 结束语

本文针对智能算法在求解优化问题时 DE 易陷入局部最优以及 GWO 易出现早熟的缺陷,提出了一

种将进化算法应用到灰狼优化算法中的混合优化算法。利用 DE 的变异、选择维持种群的多样性,然后引入灰狼算法对种群位置进行更新、及 DE 的交叉和选择操作。通过对 3 个测试函数的仿真表明,与 DE 和 GWO 相比,DEGWO 算法的寻优性能和稳定性都得到了的显著提高。

参 考 文 献

1 Price K, Storn R, Lampinen J. Differential evolution; a practical approach for global optimization. Berlin: Springer,2005

2 Storn R, Price K. Differential evolution-a simple and efficient adaptive scheme for global optimization over continuous spaces/ Technical Report TR-95-012, International Computer Science Institute, Berkley,1995

3 Mirjalili S, Mirjalili S M, Lewis A. Grey wolf optimizer. Advances in Engineering Software,2014;69(7): 46—61

4 罗 佳,唐 斌. 基于收敛因子非线性动态变化的灰狼优算法. 中国科技论文,2016;11(17): 1991—1997

Luo J,Tang B. Grey wolf optimization algorithm based on nonlinear convergence factor dynamic changing. China Science Paper, 2016; 11(17): 1991—1997

5 杨 妍,陈如清,俞金寿. 差分进化粒子群混合优化算法的研究与应用. 计算机工程与应用,2010;46(25):238—241

Yang Y, Chen R Q, Yu J S. Study on differential evolution-particle swarm optimization based hybrid optimization algorithm and its application. Computer Engineering and Applications,2010;46(25): 238—241

6 龙 文,蔡绍洪,焦建军. 求解高维优化问题的混合灰狼优化算法. 控制与决策,2016;31(11): 1991—1997

Long W, Cai S H, Jiao J J. Hybrid grey wolf optimization algorithm for high-dimensional optimization. Control and Decision, 2016; 31(11): 1991—1997

A Hybrid Optimization Algorithm Based on Differential Evolution and Grey Wolf Optimizer

JIN Xing, SHAO Zhu-chao, WANG Sheng-hui*

(School of Electrical and Electronic Engineering, Chang Chun University of Technology, Changchun 130012, P. R. China)

[Abstract] In order to overcome these disadvantages that differential evolution is easy to fall into local optimum and grey wolf optimizer behaves premature convergence easily, a hybrid optimization algorithm (DEGWO) based on the combination of differential evolution (DE) and grey wolf optimizer (GWO) is proposed. The differential mutation and selection operations of differential evolution are used to maintain the diversity of the population. Then GWO is introduced to carry out for global exploration, followed by crossover and selection operations. In the whole optimization process, this can be iterated repeatedly and behave convergence gradually. Three test functions were chosen to verify the effect. the results show the hybrid optimization algorithm has significantly improved the accuracy, convergence speed and search ability compared with the DE algorithm and the GWO algorithm.

[Key words] differential evolution grey wolf optimizer hybrid optimization algorithm test function